

ĐỀ XUẤT DỰ ÁN

Giải bài toán mê cung bằng Reinforcement Learning

Ứng dụng Actor–Critic, Soft Actor-Critic, Curriculum Learning và Intrinsic Curiosity

Tên dự án: Xây dựng tác tử học tăng cường để giải mê cung

Nhóm thực hiện: Nhóm 8

- Trần Đình Nam - **202400063**

- Nguyễn Đức Khải - **202400049**

- Phạm Việt Tiến - **202416366**

1. Giới thiệu đề tài

Bài toán mê cung là một bài toán kinh điển trong trí tuệ nhân tạo và điều hướng tự động. Mục tiêu là xây dựng một tác tử có khả năng di chuyển từ vị trí bắt đầu đến vị trí đích trong môi trường có nhiều chướng ngại vật và đường đi phức tạp. Trong các phương pháp truyền thống, bài toán này thường được giải bằng những thuật toán tìm kiếm như DFS, BFS, Dijkstra hoặc A*. Tuy nhiên, các phương pháp này chủ yếu hiệu quả khi cấu trúc môi trường đã được biết trước hoặc có sẵn heuristic phù hợp.

Trong khi đó, Reinforcement Learning (RL) cho phép tác tử học trực tiếp thông qua quá trình tương tác với môi trường. Tác tử sẽ quan sát trạng thái hiện tại, chọn hành động, nhận phần thưởng và điều chỉnh chiến lược theo thời gian. Nhờ vậy, thay vì được cung cấp sẵn đường đi đúng, tác tử có thể tự khám phá và học ra chính sách hành động hiệu quả.

Dự án này tập trung xây dựng một hệ thống giải mê cung bằng Reinforcement Learning, trong đó kết hợp các kỹ thuật hiện đại gồm Actor–Critic, Soft Actor-Critic (SAC), Curriculum Learning và Intrinsic Curiosity. Cách tiếp cận này không chỉ giúp tác tử học đường đi trong mê cung mà còn tạo nền tảng để mở rộng sang các bài toán điều hướng phức tạp hơn như robot tự hành hoặc điều khiển thông minh trong môi trường chưa biết trước.

2. Mục tiêu dự án

2.1. Mục tiêu tổng quát

Xây dựng và đánh giá một tác tử Reinforcement Learning có khả năng giải mê cung hiệu quả bằng cách kết hợp mô hình Actor–Critic, thuật toán Soft Actor-Critic, Curriculum Learning và Intrinsic Curiosity.

2.2. Mục tiêu cụ thể

- Mô hình hóa mê cung thành một môi trường học tăng cường.
- Xây dựng tác tử dựa trên kiến trúc Actor–Critic.
- Triển khai thuật toán Soft Actor-Critic để tối ưu chính sách hành động.
- Áp dụng Curriculum Learning để huấn luyện tác tử từ môi trường dễ đến khó.
- Tích hợp Intrinsic Curiosity để tăng khả năng khám phá trong môi trường có phần thưởng thưa.
- Đánh giá hiệu quả mô hình thông qua các chỉ số như tỉ lệ thành công, số bước trung bình, tổng phần thưởng và tốc độ hội tụ.

3. Phát biểu bài toán

Cho một mê cung, tác tử xuất phát từ vị trí ban đầu và cần tìm đường tới đích. Tại mỗi thời điểm t , tác tử quan sát trạng thái s_t , thực hiện hành động a_t , nhận phần thưởng r_t và chuyển sang trạng thái mới s_{t+1} . Mục tiêu là học được chính sách tối ưu $\pi(a|s)$ sao cho tổng phần thưởng tích lũy là lớn nhất:

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right]$$

Trong đó:

- s_t là trạng thái môi trường tại thời điểm t ,
- a_t là hành động của tác tử,
- r_t là phần thưởng nhận được,
- γ là hệ số chiết khấu.

Khó khăn của bài toán nằm ở chỗ tác tử không biết trước cấu trúc mê cung, đồng thời tín hiệu phần thưởng thường rất thưa. Nếu chỉ nhận thưởng khi đến đích, tác tử có thể mất rất nhiều thời gian để học được hành vi phù hợp. Vì vậy, bài toán không chỉ yêu cầu tìm đường đúng mà còn đòi hỏi thiết kế cơ chế học hiệu quả để hỗ trợ khám phá và tăng tốc hội tụ.

4. Phương pháp tiếp cận

4.1. Kiến trúc Actor–Critic

Actor–Critic là một kiến trúc phổ biến trong Reinforcement Learning, gồm hai thành phần chính:

- **Actor**: chịu trách nhiệm học chính sách, tức là quyết định hành động nào nên được chọn trong từng trạng thái.
- **Critic**: chịu trách nhiệm đánh giá chất lượng của hành động hoặc trạng thái, từ đó cung cấp tín hiệu phản hồi để Actor cập nhật hiệu quả hơn.

Ưu điểm của Actor–Critic là kết hợp được khả năng tối ưu trực tiếp chính sách với khả năng đánh giá giá trị, nhờ đó phù hợp với các môi trường phức tạp hơn so với các phương pháp chỉ dựa trên bảng giá trị đơn giản.

4.2. Soft Actor-Critic

Soft Actor-Critic là thuật toán học tăng cường ngoài chính sách, tối ưu không chỉ phần thưởng kỳ vọng mà còn cả entropy của chính sách. Việc tối đa entropy giúp tác tử duy trì khả năng khám phá trong quá trình học, tránh rơi quá sớm vào một chiến lược chưa tối ưu.

$$\pi^* = \arg \max_{\pi} \sum_t \mathbb{E}_{(s_t, a_t) \sim \pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))]$$

Trong đó:

- $\mathcal{H}$ là entropy của chính sách,
- α là hệ số cân bằng giữa tối đa hóa phần thưởng và duy trì khám phá.

SAC được lựa chọn vì có khả năng học ổn định, hiệu quả trong môi trường có không gian trạng thái lớn, đồng thời tận dụng được replay buffer để tái sử dụng kinh nghiệm trong quá trình huấn luyện.

4.3. Curriculum Learning

Curriculum Learning là chiến lược huấn luyện từ dễ đến khó. Thay vì cho tác tử học ngay trên các mê cung phức tạp, quá trình huấn luyện sẽ bắt đầu với những môi trường đơn giản hơn, ví dụ mê cung nhỏ, ít chướng ngại vật hoặc khoảng cách tới đích ngắn. Khi tác tử đạt hiệu suất nhất định, độ khó của môi trường sẽ tăng dần.

Ý tưởng này giúp tác tử hình thành trước các kỹ năng cơ bản như di chuyển, tránh va chạm và nhận biết hướng đi có lợi. Sau đó, tác tử mới tiếp tục học cách thích nghi với các mê cung lớn hơn và phức tạp hơn. Curriculum Learning giúp giảm khó khăn ở giai đoạn đầu huấn luyện, cải thiện tốc độ hội tụ và tăng tính ổn định của mô hình.

4.4. Intrinsic Curiosity

Một hạn chế lớn trong bài toán mê cung là phần thưởng ngoại sinh thường rất thưa. Nếu tác tử chỉ được thưởng khi tới đích, nó có thể không có đủ tín hiệu để học trong thời gian ngắn. Intrinsic Curiosity được đưa vào để giải quyết vấn đề này bằng cách bổ sung phần thưởng nội tại.

Cụ thể, tác tử sẽ nhận thêm động lực khám phá khi đi tới những trạng thái mới hoặc những trạng thái khó dự đoán. Nhờ đó, thay vì chỉ chờ thưởng từ môi trường, tác tử còn có xu hướng chủ động khám phá các vùng chưa biết trong mê cung. Điều này đặc biệt quan trọng trong những mê cung lớn, nhiều ngõ cụt hoặc có cấu trúc phức tạp.

Tổng phần thưởng của hệ thống có thể được thiết kế như sau:

$$r_t^{total} = r_t^{extrinsic} + \beta r_t^{intrinsic}$$

Trong đó:

- $r_t^{extrinsic}$ là phần thưởng từ môi trường,
- $r_t^{intrinsic}$ là phần thưởng nội tại từ curiosity,
- β là hệ số cân bằng giữa hai thành phần.

5. Thiết kế hệ thống

Hệ thống đề xuất gồm các thành phần chính sau:

1. **Môi trường mê cung:** mô phỏng trạng thái, hành động, chương ngại vật, vị trí đích và cơ chế phần thưởng.
2. **Actor Network:** sinh hành động dựa trên trạng thái hiện tại.
3. **Critic Network:** đánh giá giá trị hành động để hỗ trợ tối ưu chính sách.
4. **Replay Buffer:** lưu trữ kinh nghiệm để phục vụ huấn luyện theo kiểu off-policy.
5. **Curriculum Manager:** điều chỉnh độ khó của mê cung theo tiến độ học.
6. **Curiosity Module:** tạo phần thưởng nội tại nhằm tăng cường khám phá.
7. **Evaluation Module:** kiểm thử tác tử sau huấn luyện và thống kê kết quả.

Về mặt phần thưởng, hệ thống dự kiến áp dụng:

- thưởng lớn khi tác tử tới đích,
- phạt nhẹ cho mỗi bước đi nhằm khuyến khích tìm đường ngắn,
- phạt khi va chạm hoặc thực hiện hành động không hợp lệ,
- thưởng nội tại khi khám phá trạng thái mới.

Thiết kế này nhằm tạo ra sự cân bằng giữa mục tiêu chính là tới đích nhanh chóng và mục tiêu phụ là khám phá môi trường hiệu quả.

6. Phương pháp đánh giá và kết quả mong đợi

6.1. Hiệu quả của mô hình sẽ được đánh giá dựa trên các tiêu chí:

- tỉ lệ tác tử thoát mê cung thành công,
- số bước trung bình để tới đích,
- tổng phần thưởng trung bình theo từng giai đoạn huấn luyện,
- tốc độ hội tụ của mô hình,
- khả năng thích nghi khi độ khó mê cung tăng dần.

6.2. Kết quả mong đợi của dự án:

- xây dựng thành công hệ thống giải mê cung bằng Reinforcement Learning,
- tác tử học được đường đi hiệu quả trong nhiều mức độ mê cung,
- chứng minh được rằng Curriculum Learning giúp quá trình huấn luyện ổn định hơn,
- chứng minh được rằng Intrinsic Curiosity giúp tăng khả năng khám phá trong môi trường phần thưởng thưa,
- thu được các biểu đồ và kết quả trực quan phục vụ phân tích và báo cáo.

7. Kết luận

Đề tài giải mê cung bằng Reinforcement Learning là một hướng nghiên cứu có ý nghĩa cả về học thuật lẫn thực tiễn. Việc kết hợp Actor-Critic, Soft Actor-Critic, Curriculum Learning và Intrinsic Curiosity cho phép xây dựng một tác tử có khả năng học đường đi trong môi trường phức tạp, đồng thời cải thiện khả năng khám phá và tốc độ hội tụ. Dự án không chỉ phù hợp để tìm hiểu các nguyên lý cốt lõi của học tăng cường mà còn tạo nền tảng cho các ứng dụng nâng cao hơn như robot tự hành, điều hướng thông minh và hệ thống ra quyết định trong môi trường động.